

Procesó durante 1m 45s

Sí. Revisando el **sílabo**, las sesiones de Big Data que adjuntaste y el archivo `SQL-Capas.sql`, la idea puede plantearse como un proyecto real de Big Data Analytics y, al mismo tiempo, quedar claramente alineada con lo que están viendo en clase.

La propuesta que te recomiendo trabajar es:

## FEN-RISK Perú: Plataforma Big Data para el análisis y anticipación de impactos del Fenómeno El Niño en la costa peruana

El enfoque no sería simplemente “predecir El Niño”, porque eso ya es un problema climatológico mucho más complejo. El proyecto se enfocaría en **integrar señales oceanográficas, meteorológicas y registros históricos de emergencias para identificar distritos con mayor probabilidad de experimentar impactos asociados a lluvias intensas durante episodios de El Niño Costero.**

El tema encaja muy bien con el curso porque el sílabo exige que el proyecto integrador identifique un caso de uso, proponga una arquitectura de datos y desarrolle una solución basada en procesamiento distribuido, justificando escalabilidad, rendimiento, viabilidad y generación de valor.

Sílabo-A-170216-Big Data Analyt... +1

Propuesta de proyecto Big Data Analytics — Fenómeno El ...

### 1. Problemática

#### 1.1 Planteamiento del problema

El Fenómeno El Niño representa un problema recurrente para el Perú debido a su capacidad de alterar las condiciones oceánicas y atmosféricas y generar lluvias intensas, inundaciones, desbordes de ríos y daños sobre población, viviendas, infraestructura, agricultura y transporte.

La problemática no consiste únicamente en la existencia del fenómeno climático, sino en la **dispersión y heterogeneidad de la información necesaria para anticipar sus impactos territoriales.**

Actualmente existen distintas fuentes de información:

- variables meteorológicas provenientes de estaciones del SENAMHI;
- índices oceánicos asociados a El Niño, como Niño 1+2 y Niño 3.4;

- registros históricos de emergencias y daños provenientes del SINPAD/INDECI;
- información geográfica asociada a departamentos, provincias y distritos.

Estas fuentes presentan diferentes estructuras, frecuencias temporales y niveles de granularidad. Por ello, existe una oportunidad para construir un pipeline Big Data que permita **integrarlas, limpiarlas, transformarlas y analizarlas de manera distribuida**.

La relevancia del problema es particularmente alta en el contexto actual. En su comunicado del **14 de septiembre de 2026**, ENFEN mantiene el estado de “**Alerta de El Niño Costero**” y señala que el evento en la región Niño 1+2 podría continuar hasta mediados del otoño de 2027; además, señala una mayor probabilidad de magnitud extraordinaria entre septiembre de 2026 y enero de 2027 y condiciones de lluvia por encima de lo normal en la costa norte, con posibles episodios de intensidad moderada a fuerte desde noviembre.

Por tanto, la pregunta central del proyecto sería:

**¿Cómo utilizar Big Data Analytics para integrar información meteorológica, oceanográfica e histórica de emergencias y generar indicadores territoriales que permitan identificar oportunamente zonas con mayor exposición a impactos asociados al Fenómeno El Niño Costero?**

## 1.2 Problema específico

La solución buscará responder preguntas como:

**¿Qué relación existe entre las anomalías de temperatura superficial del mar, las precipitaciones y la ocurrencia de emergencias en la costa peruana?**

**¿Qué departamentos/provincias/distritos presentan históricamente mayor recurrencia de emergencias durante episodios asociados a El Niño?**

**¿Qué características meteorológicas preceden a los eventos de mayor afectación?**

**¿Puede construirse un indicador de riesgo territorial utilizando estas variables?**

---

## 2. ¿Por qué esta problemática es adecuada para Big Data?

La problemática se adapta a las dimensiones que se han visto en clase.

| Dimensión     | Aplicación al proyecto                                                                       |
|---------------|----------------------------------------------------------------------------------------------|
| Volumen       | Históricos de estaciones meteorológicas + emergencias + índices climáticos                   |
| Velocidad     | Datos meteorológicos con frecuencia horaria y posibilidad de incorporar nuevas observaciones |
| Variedad      | CSV, registros tabulares, variables temporales, variables geográficas e índices climáticos   |
| Valor         | Transformar datos dispersos en indicadores útiles para gestión del riesgo                    |
| Escalabilidad | Procesamiento con Apache Spark                                                               |

En el material del curso Big Data se define precisamente el problema desde dimensiones como volumen, velocidad, variedad y valor, y se establece como objetivo integrar fuentes de datos, reducir tiempos de procesamiento y aumentar la exactitud de los cálculos.

Además, el curso plantea explícitamente el uso de paralelización, escalabilidad, alta disponibilidad, Hadoop, Spark y Kafka dentro del ecosistema Big Data.

### 3. Referencias que justifican la problemática

#### Referencia 1 — ENFEN, situación actual

El comunicado oficial ENFEN N.º 16-2026 establece que Perú se encuentra bajo **Alerta de El Niño Costero**. Para la región Niño 1+2, ENFEN prevé continuidad del evento y señala una mayor probabilidad de magnitud extraordinaria entre septiembre de 2026 y enero de 2027. También prevé lluvias superiores a lo normal en la costa norte y posibles episodios de lluvias moderadas a fuertes desde noviembre.

Este documento es especialmente importante para la introducción del proyecto porque demuestra que la problemática **no es únicamente histórica**, sino vigente en 2026.

Comunicado Oficial ENFEN N.º 16-2026

#### Referencia 2 — INDECI

INDECI dispone de un conjunto de datos de emergencias y evaluación de daños provenientes del SINPAD. El dataset contiene información de emergencias y peligros a nivel nacional y variables relacionadas con fallecidos, desaparecidos, lesionados, damnificados, afectados, viviendas, infraestructura educativa y de salud, red vial y agricultura. Además, proporciona microdatos consolidados a nivel distrital.

Esto es fundamental porque permite utilizar las **afectaciones reales como variable objetivo o evidencia histórica del impacto**.

### Referencia 3 — evidencia histórica del impacto

El INDECI reportó para el Niño Costero 2017 importantes afectaciones humanas e infraestructura. En uno de sus compendios se registraron más de 1.7 millones de personas entre damnificadas y afectadas en el procesamiento realizado al 4 de julio de 2017.

Otro documento oficial reporta para el evento de 2017 pérdidas económicas estimadas en aproximadamente **US\$3,100 millones**, además de daños importantes en viviendas, carreteras, puentes, instituciones educativas y agricultura.

El Banco Mundial también reporta daños de aproximadamente US\$3.1 mil millones asociados al Niño Costero de 2017 y documenta la afectación particularmente importante de infraestructura en el norte del país.

---

## 4. Proyectos y antecedentes relacionados

### Antecedente 1 — Machine Learning para pronóstico de precipitación en Perú

El IGP publicó en 2023 un trabajo sobre el desarrollo de un modelo de Machine Learning para pronosticar precipitaciones en Perú a escala subestacional.

El estudio utiliza información del proyecto Subseasonal to Seasonal, realiza downscaling tomando como referencia PISCO del SENAMHI, aplica Análisis de Componentes Principales y regresión lineal múltiple. El trabajo reporta buen desempeño hasta aproximadamente cinco días, con disminución de la capacidad predictiva para horizontes mayores.

Proyecto IGP — Machine Learning para precipitación en Perú

#### Relación con nuestro proyecto

El antecedente demuestra que ML puede utilizarse para estudiar precipitación en Perú.

**Nuestro proyecto ampliaría el problema desde la predicción meteorológica hacia la relación entre condiciones climáticas e impactos territoriales registrados.**

---

## **Antecedente 2 — Análisis espacio-temporal de precipitaciones y caudales**

Una investigación de la Universidad Nacional Agraria La Molina estudió la variabilidad espacio-temporal de precipitaciones y caudales durante los eventos El Niño 1982-83 y 1997-98 en Tumbes y Piura.

El estudio relacionó las precipitaciones con diferentes indicadores de El Niño y encontró patrones espaciales y temporales asociados a eventos extraordinarios.

Investigación UNALM — Precipitaciones y caudales durante El Niño

### **Relación con nuestro proyecto**

Este trabajo proporciona una base científica para relacionar:

**El Niño → precipitación → comportamiento hidrológico → impactos.**

Nuestro proyecto trasladaría esta lógica a un pipeline de procesamiento Big Data.

---

## **Antecedente 3 — Patrones de precipitación durante El Niño**

El IGP también documentó patrones diarios de precipitación durante los eventos extraordinarios de 1982-83 y 1997-98 en la costa norte peruana, indicando que El Niño puede producir lluvias intensas e inundaciones en esta zona.

Estudio IGP — Patrones diarios de precipitación durante El Niño

---

## **Antecedente 4 — Análisis multidimensional de daños del FEN**

En 2025, el IGP publicó un análisis multidimensional de los daños del Fenómeno El Niño de 2017 a nivel departamental.

El estudio aplicó el enfoque MDDA a los FEN de 1982-83, 1997-98 y 2017 y encontró que, para 2017, los departamentos costeros de Arequipa, Ica, Lima, Áncash, La Libertad, Lambayeque, Piura y Tumbes acumularon el 85 % del total de los daños analizados. El estudio también propone ampliar el análisis a niveles provincial y distrital y aplicar el enfoque a eventos posteriores.

IGP — Análisis multidimensional de daños del FEN 2017

---

## **Esto nos da un punto especialmente interesante**

El propio estudio plantea como trabajo futuro extender el análisis a nivel **provincial y distrital** y a eventos recientes.

Por eso, nuestra propuesta puede enfocarse precisamente en construir un pipeline de datos que permita ese análisis territorial.

---

## **5. Factor diferenciador**

El factor diferenciador no debería plantearse como “hacer otro modelo de predicción de El Niño”, porque existen investigaciones científicas que ya realizan predicción climática.

El factor diferenciador propuesto es:

**Integrar en una misma arquitectura Big Data las condiciones de El Niño, variables meteorológicas y evidencia histórica de impactos, para producir indicadores de riesgo a nivel territorial.**

La diferencia puede representarse así:

### **Proyectos tradicionales**

El Niño → temperatura del mar → precipitación

### **Nuestro proyecto**

El Niño

↓

Variables meteorológicas

↓

Preprocesamiento Big Data

↓

Cruce temporal y territorial

↓

Histórico de emergencias y daños

↓

Features

↓

Indicador de impacto/riesgo por distrito

Esto hace que el resultado deje de ser solamente una serie climatológica y se convierta en una **herramienta analítica orientada al impacto**.

Además, el uso de **Niño 1+2** y **Niño 3.4** permite diferenciar la señal del calentamiento asociado al Pacífico oriental de un indicador más amplio del ENSO. NOAA dispone de series históricas mensuales de estos índices; la serie Niño 1+2 representa la anomalía de SST en el Pacífico tropical oriental, región particularmente relevante para el contexto peruano.

---

## 6. Arquitectura propuesta

La arquitectura debe estar alineada con las capas que ya trabajaron en el archivo


`SQL-Capas.sql`.


En el ejercicio del profesor se plantea justamente el procesamiento por capas:

**Workload → Landing → Curated → Functional**

y se realizan operaciones de conteo, transformación, `CAST`, `REPLACE`, agregación y generación de tablas funcionales.

### Arquitectura conceptual





## Tecnología propuesta

| Componente                | Tecnología          |
|---------------------------|---------------------|
| Ingesta                   | Python / Databricks |
| Procesamiento             | Apache Spark        |
| Consultas                 | Spark SQL           |
| DataFrames                | PySpark             |
| Almacenamiento inicial    | CSV                 |
| Almacenamiento optimizado | Parquet             |

|                       |                       |
|-----------------------|-----------------------|
| Arquitectura de datos | Data Lake / Lakehouse |
| Procesamiento         | Batch inicialmente    |
| Analytics             | Spark SQL             |
| ML futuro             | Spark MLlib           |

Esta arquitectura está directamente relacionada con lo visto en las sesiones.

El material del curso define Apache Spark como un motor de procesamiento distribuido paralelo en memoria y destaca su escalabilidad.

También se revisaron Spark Core, Spark SQL, Spark Streaming y MLlib.

**En la siguiente sesión se trabajaron explícitamente SparkSession, DataFrames, DDL, tablas, Parquet, particionamiento, JOINS y Window Functions.**

## 7. ¿Qué datos utilizaría?

### Fuente 1 — SENAMHI

Esta sería la principal fuente meteorológica.

El conjunto publicado por SENAMHI contiene registros horarios validados de:

- temperatura;
- humedad relativa;
- precipitación;
- fecha/hora;
- estación;
- latitud;
- longitud;
- altitud;
- departamento;
- provincia;
- distrito;
- UBIGEO.

El dataset es CSV y está publicado en la Plataforma Nacional de Datos Abiertos.

**Link exacto al dataset**

## Portal oficial de descarga hidrometeorológica

[SENAMHI — Descarga de datos hidrometeorológicos](#)

Para tu proyecto, filtraría inicialmente estaciones de:

**Tumbes, Piura, Lambayeque y La Libertad.**

Posteriormente se puede ampliar a Áncash.

---

## 8. Fuente 2 — INDECI / SINPAD

Esta será la fuente utilizada para representar el **impacto real**.

Contiene registros de emergencias y evaluación de daños a nivel nacional, incluyendo variables de población, vivienda, educación, salud, red vial y agricultura. El dataset proporciona microdatos consolidados a nivel distrital.

### Link exacto

[INDECI — Emergencias y daños a nivel nacional por departamento / SINPAD](#)

Este dataset es especialmente útil porque puede convertirse en la variable objetivo:

```
emergencia = 1  
sin emergencia = 0
```

o alternativamente:

```
nivel_impacto =  
0 → sin afectación relevante  
1 → afectación baja  
2 → afectación media  
3 → afectación alta
```

La definición exacta dependerá de las variables disponibles en el CSV.

---

## 9. Fuente 3 — NOAA Niño 1+2

Para representar el comportamiento del Pacífico oriental se puede utilizar la serie histórica Niño 1+2.

NOAA/PSL documenta esta serie y señala que corresponde a anomalías de temperatura superficial del mar en la región Niño 1+2.

### CSV crudo directo

<https://psl.noaa.gov/data/correlation/nina1.anom.csv>

También existe la serie en formato de texto:

<https://psl.noaa.gov/data/correlation/nina1.anom.data>

---

## 10. Fuente 4 — NOAA Niño 3.4

Para complementar la información con una medida del ENSO en el Pacífico central:

### CSV crudo directo

<https://psl.noaa.gov/data/correlation/nina34.anom.csv>

La serie tiene datos mensuales y NOAA indica que el índice es calculado por NOAA/CPC a partir del producto ERSST.

También está disponible en formato texto:

<https://psl.noaa.gov/data/correlation/nina34.anom.data>

---

## 11. Resultado preliminar esperado — limpieza

Aquí es donde podemos demostrar que estamos utilizando **exactamente los conceptos de las clases**.

La sesión de Spark plantea un pipeline con:

**Ingesta** → **Limpieza** → **Enriquecimiento** → **Agregación** → **Escritura**, incluyendo eliminación de nulos, validación de tipos, deduplicación, JOIN y generación de KPIs.

### 11.1 Landing

Primero se mantiene el dataset prácticamente sin modificar.

Ejemplo:

```
CREATE TABLE fen.meteorologia_landing (  
    fecha STRING,  
    hora STRING,  
    estacion STRING,  
    ubigeo STRING,  
    departamento STRING,  
    provincia STRING,  
    distrito STRING,  
    temperatura STRING,  
    humedad STRING,  
    precipitacion STRING  
)  
USING CSV;
```

La idea de Landing es **preservar el RAW antes de transformar**.

---

## 12. Resultado preliminar — Curated

En esta capa se aplicaría la limpieza.

### Limpieza de texto

```
REPLACE(departamento, '"', '')  
REPLACE(provincia, '"', '')  
REPLACE(distrito, '"', '')
```

### Conversión de tipos

```
CAST(temperatura AS DOUBLE)  
CAST(humedad AS DOUBLE)  
CAST(precipitacion AS DOUBLE)
```

### Fecha

```
TO_DATE(fecha)
```

### Eliminación de registros inválidos

```
df = df.dropna()
```

### Eliminación de duplicados

```
df = df.dropDuplicates(  
    ["estacion", "fecha", "hora"]
```

)

Estos procesos reflejan directamente los ejemplos de limpieza que aparecen en la sesión: eliminar nulos, validar tipos y deduplicar.

También son consistentes con el procedimiento utilizado en `SQL-Capas.sql`, donde se realiza `CAST` y `REPLACE` para transformar la información de Landing a Curated.

---

## 13. Resultado preliminar — enriquecimiento

Una vez limpias las fuentes, se realizaría el JOIN.

Por ejemplo:

```
SELECT
    m.fecha,
    m.departamento,
    m.provincia,
    m.distrito,
    m.precipitacion,
    n.nino12,
    n.nino34,
    s.emergencia
FROM meteorologia_curated m

LEFT JOIN nino_curated n
    ON YEAR(m.fecha) = n.anio
    AND MONTH(m.fecha) = n.mes

LEFT JOIN sinpad_curated s
    ON m.ubigeo = s.ubigeo
    AND m.fecha = s.fecha;
```

Esto aplica el concepto de **JOIN** trabajado en clase.

---

## 14. Resultado preliminar — generación de indicadores

Aquí el proyecto comienza a convertirse en Analytics.

Por ejemplo:

## Precipitación acumulada de 3 días

```
SUM(precipitacion) OVER (  
    PARTITION BY estacion  
    ORDER BY fecha  
    ROWS BETWEEN 2 PRECEDING AND CURRENT ROW  
)
```

## Precipitación acumulada de 7 días

```
SUM(precipitacion) OVER (  
    PARTITION BY estacion  
    ORDER BY fecha  
    ROWS BETWEEN 6 PRECEDING AND CURRENT ROW  
)
```

## Promedio histórico

```
AVG(precipitacion) OVER (  
    PARTITION BY distrito, MONTH(fecha)  
)
```

## Número de emergencias

```
COUNT(*)  
GROUP BY departamento, provincia, distrito
```

Esto utiliza directamente las **Window Functions**, `SUM() OVER()`, `AVG() OVER()`, `COUNT() OVER()`, `LAG()` y `LEAD()` vistas en la clase.

---

# 15. Resultado preliminar — capa Functional

La capa Functional podría generar una tabla como:

```
fen_risk_functional  
-----  
fecha  
ubigeo  
departamento  
provincia  
distrito  
precip_1d  
precip_3d  
precip_7d
```

temp\_promedio  
humedad\_promedio  
nino12  
nino34  
emergencias\_historicas  
afectados\_historicos  
indice\_impacto

Esto sigue exactamente la lógica del ejercicio realizado en `SQL-Capas.sql` , donde Curated alimenta una capa Functional con indicadores agregados.

## 16. ¿Qué resultados preliminares se pueden presentar?

En la primera entrega yo presentaría estos resultados:

| Resultado                | Qué demostrar           |
|--------------------------|-------------------------|
| Dataset RAW cargado      | Ingesta                 |
| Número de registros      | <code>COUNT ()</code>   |
| Esquema original         | <code>DESCRIBE</code>   |
| Registros nulos          | Data Quality            |
| Registros duplicados     | Deduplicación           |
| Campos convertidos       | <code>CAST ()</code>    |
| Texto estandarizado      | <code>REPLACE ()</code> |
| Dataset Curated          | Limpieza                |
| JOIN meteorología + Niño | Enriquecimiento         |
| JOIN con SINPAD          | Relación clima-impacto  |
| Precipitación diaria     | <code>GROUP BY</code>   |
| Precipitación 3/7 días   | Window Functions        |
| Emergencias por distrito | Agregación              |

Esto queda muy alineado con el pipeline mostrado por el docente: cargar, limpiar, enriquecer, agregar y escribir los resultados.

---

## 17. Uso de Parquet

Una vez realizada la limpieza:

```
df.write \
    .format("parquet") \
    .mode("overwrite") \
    .save("/fen_risk/curated/")
```

La elección de Parquet está especialmente justificada por las clases, donde se señala que para Spark es un formato recomendado y que la organización columnar favorece el rendimiento de consulta.

En la siguiente sesión también se revisó explícitamente Parquet y el particionamiento de tablas.

Una estructura podría ser:

```
/fen_risk/
  /landing/
    /senamhi/
    /indeci/
    /noaa/

  /curated/
    /meteorologia/
    /sinpad/
    /nino/

  /functional/
    /riesgo_distrital/
    /kpis/
```

---

## 18. Modelo analítico posterior

El sílabo contempla una cuarta unidad dedicada a Analítica Avanzada y Machine Learning en Big Data.

Por ello, el proyecto puede tener dos etapas.

### Etapas 1 — Big Data Analytics

```
RAW
↓
Landing
↓
Curated
↓
JOIN
↓
Agregaciones
↓
Features
↓
Functional
```

### Etapas 2 — Machine Learning

Con las features generadas:

```
precip_1d
precip_3d
precip_7d
temp
humedad
nino12
nino34
emergencias_históricas
```

se podría entrenar un modelo para estimar:

```
P(impacto alto | condiciones climáticas)
```

Por ejemplo, una primera alternativa metodológica podría ser una **clasificación binaria**:

```
0 = no se registra emergencia de alto impacto
1 = se registra emergencia de alto impacto
```

La implementación del modelo se puede realizar posteriormente con **Spark MLlib**, que forma parte del ecosistema revisado en clase.

## 19. Fuentes RAW que utilizaría definitivamente

| Fuente        | Información                                           | Formato | Uso                      |
|---------------|-------------------------------------------------------|---------|--------------------------|
| SENAMHI       | Temperatura, humedad, precipitación, estación, UBIGEO | CSV     | Variables meteorológicas |
| INDECI/SINPAD | Emergencias y daños                                   | CSV     | Variable de impacto      |
| NOAA Niño 1+2 | Anomalía SST Pacífico oriental                        | CSV     | Señal El Niño            |
| NOAA Niño 3.4 | Anomalía SST Pacífico central                         | CSV     | Señal ENSO               |

### Links exactos

#### SENAMHI — CSV meteorológico:

[Dataset oficial SENAMHI](#)

#### SENAMHI — portal de descarga:

[Descarga oficial de datos hidrometeorológicos SENAMHI](#)

#### INDECI — SINPAD CSV:

[Dataset oficial INDECI/SINPAD](#)

#### NOAA — Niño 1+2 CSV RAW:

<https://psl.noaa.gov/data/correlation/nina1.anom.csv>

#### NOAA — Niño 3.4 CSV RAW:

<https://psl.noaa.gov/data/correlation/nina34.anom.csv>

#### ENFEN — comunicado actual:

[Comunicado ENFEN N.º 16-2026](#)

## 20. Cómo vendería el proyecto en la sustentación

La idea central que defendería sería:

**“El proyecto no busca solamente analizar el Fenómeno El Niño, sino transformar múltiples fuentes heterogéneas de información climática y de impactos en una plataforma Big Data capaz de procesar información a escala territorial y generar indicadores que permitan identificar patrones de afectación asociados a eventos de El Niño Costero.”**

Y la arquitectura se justifica porque el curso plantea precisamente el uso de Big Data para integrar fuentes, procesar grandes volúmenes de información, reducir tiempos y generar valor.

Además, el ejercicio del profesor pide explícitamente escoger un dataset y aplicar el procesamiento por **Workload, Landing, Curated y Functional**, que es exactamente el patrón que puede utilizar este proyecto.

### **Nombre final sugerido**

**FEN-RISK Perú: Sistema Big Data para la integración y análisis predictivo de impactos asociados al Fenómeno El Niño Costero**

### **Objetivo general**

**Diseñar e implementar una arquitectura Big Data utilizando Apache Spark para integrar datos meteorológicos, índices oceánicos y registros históricos de emergencias, con el propósito de identificar patrones e indicadores territoriales asociados a los impactos del Fenómeno El Niño Costero en el Perú.**

La propuesta está deliberadamente construida sobre lo que ya aparece en tus materiales: **arquitecturas, Data Lake/Lakehouse, capas Workload/Landing/Curated/Functional, Spark, Spark SQL, DataFrames, CAST, REPLACE, limpieza, JOIN, GROUP BY, Window Functions y Parquet.**

[1] Sesión 6 (BDA) +1

SQL-Capas

Un punto importante: **no he presentado números inventados como “resultados de limpieza”**. Los resultados cuantitativos reales —cantidad de filas, nulos, duplicados, distribución por distrito, etc.— deben calcularse al cargar los CSV originales. La estructura anterior te deja exactamente qué métricas debes obtener para que la primera entrega tenga evidencia reproducible.

Fuentes